### **OBJECTIFS**

Renforcer les connaissances générales en traitement des images (computer vision)

Balayer les principales bibliothèques de traitements d'image Python (OpenCV & SKIMAGE) mieux appréhender la notion de kernel dans le traitement d'images


Comprendre l'influence des paramètres mathématiques sur la filtration des kernels et donc la sélection de caractéristiques d'images (features)

Évaluer le potentiel d'utilisation de ces notions "un peu théoriques" en machine learning & deep learning, dans la cadre du projet RAKUTEN


# TRAITEMENT IMAGE - PRÉSENTATION DES FILTRES GABOR - THÉORIE


Pour le traitement d'images et la vision par ordinateur, les filtres de Gabor sont généralement utilisé dans l'analyse de texture, la détection de contours, l'extraction de caractéristiques, etc. **Les filtres de Gabor sont des classes spéciales de filtres passe-bande**, c'est-à-dire qu'ils permettent le filtrage d'une certaine « bande » de fréquences et rejeter les autres.

Un filtre Gabor , nommé d'après Dennis Gabor , est un filtre linéaire utilisé pour l'analyse de texture , ce qui signifie essentiellement qu'il analyse s'il y a un contenu de fréquence spécifique dans l'image dans des directions spécifiques dans une région localisée autour du point ou de la zone d'analyse. Les représentations de fréquence et d'orientation des filtres de Gabor sont revendiquées par de nombreux scientifiques contemporains de la vision comme étant similaires à celles du système visuel humain . Ils se sont avérés particulièrement appropriés pour la représentation et la discrimination des textures. Dans le domaine spatial, un filtre de Gabor 2-D est une fonction à noyau gaussien modulée par une onde plane sinusoïdale



$$g(x,y;\lambda,\theta,\psi,\sigma,\gamma) = \exp\left(-\frac{x'^2 + \gamma^2 y'^2}{2\sigma^2}\right) \exp\left(i\left(2\pi\frac{x'}{\lambda} + \psi\right)\right)$$










Fig 4, 2d cos function, cos( 2  $\pi$  (x  $u_1$  + y  $v_1$ )),  $u_1$ =0.5,  $v_1$ =0






fig 5, 2d gaussian times cos function,  $\sigma_x\text{-0.5},\sigma_y\text{-0.5},~u_1\text{-1.0},~v_1\text{-1.0}$ 

## TRAITEMENT IMAGE - PRESENTATION DES FILTRES GABOR DANS LA BIBLIOTHEQUE OPEN CV

```
cv2.getGaborKernel(ksize, sigma, theta, lambda, gamma, psi, ktype)
```

-> ksize: Taille du filtre renvoyé

-> sigma: Écart-type de l'enveloppe gaussienne

-> theta: Orientation de la normale aux bandes // d'une fonction de Gabor


-> lambda: Longueur d'onde du facteur sinusoïdal

-> gamma: Aspect ratio spatial

-> **psi** Décalage de phase

- -> **ktype** Type de coefficients de filtre. Il peut s'agir de CV\_32F ou CV\_64F :indique le type et la plage de valeurs que chaque pixel du noyau Gabor peut contenir: float32 ou float64

#### TESTS UTILISATION DES FILTRES GABOR OPEN CV - IMAGES RAKUTEN




## PARAMÈTRE MODIFIÉ

ksize = 5 #Use size that makes sense to the image and fetaure size. Large may not be good.
#Un the synthetic image it is clear how ksize affects image (try 5 and 50)
sigma = 3 # Large sigma on small features will fully miss the features.
theta = 1\*np.pi/4 # 1/4 shows horizontal
lamda = 1\*np.pi/4 # 1/4 works good
gamma=0.4 #Value of 1 defines spherical. Close to 0 has high aspect ratio
phi = 0 #Phase offset



```
ksize = 30  #Use size that makes sense to the image and feature size. Large may not be good.
#On the synthetic image it is clear how ksize affects image (try 5 and 50)
sigma = 3  # Large sigma on small features will fully miss the features.
theta = 1*np.pi/4  # 1/4 shows horizontal
lamda = 1*np.pi/4  # 1/4 works good
gamma=0.4  #Value of 1 defines spherical. Close to 0 has high aspect ratio
    phi = 0 #Phase offset
```

```
ksize = 150  #Use size that makes sense to the image and feature size. Large may not be good.
#On the synthetic image it is clear how ksize affects image (try 5 and 50)
sigma = 3 # Large sigma on small features will fully miss the features.
theta = 1*np.pi/4 # 1/4 shows horizontal
lamda = 1*np.pi/4 # 1/4 works good
gamma=0.4  #Value of 1 defines spherical. Close to 0 has high aspect ratio
phi = 0 #Phase offset
```




## TESTS UTILISATION DES FILTRES GABOR OPEN CV - IMAGES RAKUTEN

## PARAMÈTRE MODIFIÉ

ksize = 150 #Use size that makes sense to the image and feature size. Large may not be good.
#On the synthetic image it is clear how ksize affects image (try 5 and 50)
sigma = 3 # Large sigma on small features will fully miss the features.
theta = 1\*np.pi/4 # 1/4 shows horizontal
lamda = 1\*np.pi/4 # 1/4 works good
gamma=10 #Value of 1 defines spherical. Close to 0 has high aspect ratio phi = 0 #Phase offset



ksize = 150 #Use size that makes sense to the image and feature size. Large may not be good.
#On the synthetic image it is clear how ksize affects image (try 5 and 50)
sigma = 3 # Large sigma on small features will fully miss the features.
theta = 3\*np.pi/4 # 1/4 shows horizontal
lamda = 3\*np.pi/4 # 1/4 works good
gamma=10 #Value of 1 defines spherical. Close to 0 has high aspect ratio
phi = 0 #Phase offset




## PARAMÈTRE MODIFIÉ

phi = 0 #Phase offset

**Original Img RGB** 


Kernel **Original Img Gray**  Filtered Img


















### TESTS UTILISATION DE PLUSIEURS FILTRES COMBINES POUR UN 1er MODÈLE DE MACHINE LEARNING - IMAGES RAKUTEN


STEP 1 -> création d'un 1er mdèle simple de ML pour en sortir les feature importances (ML4\_img\_rak.py)

```
#Define the dependent variable that needs to be predicted (labels)
Y = df["Labels"].values
 #Define the independent variables
X = df.drop(labels = ["Labels"], axis=1)
 #Split data into train and test to verify accuracy after fitting the model. from sklearn.model selection import train test split
 X train, X test, y train, y test = train Test split(X, Y, test size=0.4, random state=20)
 from sklearn.ensemble import RandomForestClassifier
 model = RandomForestClassifier(n_estimators = 100, random_state = 42)
 # Train the model on training data
 model.fit(X_train, y_train)
# verify number of trees used. If not defined above.
print('Number of Trees used : ', model.n_estimators)
# TESTING THE MODEL BY PREDICTING ON TEST DATA
 prediction test train = model.predict(X train)
#Test prediction on testing data.
prediction test = model.predict(X test)
From sklearn import metrics

#First check the accuracy on training data. This will be higher than test data prediction accuracy.

#First check the accuracy on training data = ", metrics.accuracy_score(y_train, prediction_test_train))

#Check accuracy on test dataset. If this is too low compared to train it indicates overfitting on training data
 print ("Accuracy = ", metrics.accuracy_score(y_test, prediction_test))
 #Get numerical feature importances importances = list(model.feature importances )
 feature list = list(X.columns)
 feature_imp = pd.Series(model.feature_importances_,index=feature_list).sort_values(ascending=False)
 print(feature_imp)
 import pickle
 #Save the trained model as pickle string to disk for future use
 filename = "rakuten im1"
 pickle.dump(model, open(filename, 'wb'))
 #To test the model on future datasets
loaded_model = pickle.load(open(filename, 'rb'))
result = loaded_model.predict(X)
 segmented = result.reshape((img.shape))
from matplotlib import pyplot as plt plt.imshow(segmented, cmap ='jet') plt.imsave('rakuten\_estim.jpg', segmented, cmap ='jet')
```



Filtres les + importants d'un modèle simple ML

